

Analyse en Composantes Principales

Résumer un tableau de p variables quantitatives en quelques axes, sans perdre l'essentiel.

DÉROULÉ

PLAN

Pourquoi l'ACP ?

Le problème des données en grande dimension

Les concepts clés

Information, meilleur point de vue, score

Combien d'axes ?

Critère du coude, critère de Kaiser

Lire les résultats

Cercle des corrélations, nommer les axes, lire les vins

Étude de cas

178 vins italiens, puis passage au TD

LE POINT DE DÉPART

Un tableau de n individus $\times$ p variables

	alcool	ac. malique	...	proline
vin 1	14,23	1,71	...	1065
vin 2	13,20	1,78	...	1050
vin 3	13,16	2,36	...	1185
⋮	⋮	⋮		⋮
vin 178	14,13	4,10	...	560

$n = 178$ vins, **$p = 13$** mesures chimiques quantitatives.

Chaque vin est un point dans un espace à 13 dimensions : impossible à regarder directement.

Même les nuages de points deux à deux ne suffisent pas : $13 \times 12 / 2 = \mathbf{78}$ graphiques.

L'IDÉE DE L'ACP

Trouver quelques directions qui résument le nuage de points en perdant le moins d'information possible.

Ici, « information » veut dire **variance** : la dispersion des points. Un bon axe est un axe sur lequel les individus projetés restent bien séparés.

CONCEPT 1

L'inertie : la quantité d'information du tableau

Pas de différences, pas d'information

Si les 178 vins avaient tous le même degré d'alcool, cette variable ne distinguerait aucun vin. L'information, ce sont les **différences** entre individus, mesurées par la variance.

L'inertie, variance de tout le nuage

Chaque vin est un point, le tableau est un nuage. L'inertie mesure à quel point ce nuage est étalé : c'est la **somme des variances** des 13 variables.

L'ACP range l'information

Elle n'en crée pas, n'en perd pas : elle la réorganise sur de nouveaux axes, **l'essentiel dans les premiers**, comme des cartons de déménagement numérotés.

Quand on lira « x % d'inertie sur F1 », cela voudra dire : le premier axe contient x % de l'information totale du tableau.

CONCEPT 2

Centrer-réduire : raisonner en « écarts à la normale »

Le problème

Additionner des variances brutes, c'est additionner des centimètres et des tonnes. La proline (en centaines de mg/L) écraserait la teinte (en dixièmes), juste parce qu'elle s'écrit avec de grands chiffres.

La solution

Chaque valeur devient une question : **ce vin est-il au-dessus ou en dessous de la moyenne, et de combien d'écarts-types ?**
0 = dans la moyenne · +2 = nettement au-dessus


Le résultat

Toutes les variables partent à égalité. Si l'ACP en met une en avant, c'est qu'elle **distingue vraiment** les vins, pas à cause de son unité.

CONCEPT 3


Un axe : l'angle qui donne l'ombre la plus parlante

Chameau de profil face à la lampe



L'ombre montre tête, bosses et pattes : **l'information est conservée.**

Chameau tourné vers la lampe



L'ombre n'est qu'une silhouette étroite : **l'information est perdue.**

Le chameau, c'est le nuage en 13 dimensions ; l'ombre, c'est le graphique F1–F2. **L'ACP choisit l'éclairage qui donne l'ombre la plus étalée.**

CONCEPT 4

Une composante est un score, une note finale

$$F1 = \text{poids}_1 \times \text{alcool} + \text{poids}_2 \times \text{acide malique} + \dots + \text{poids}_{13} \times \text{proline}$$

Des poids calculés par l'ACP

Comme une note finale (40 % examen, 60 % projet), mais ce n'est pas nous qui choisissons les poids : l'ACP les fixe pour que le score **sépare le plus** les individus.

Les poids donnent le sens

Poids fort et positif : la variable tire le score vers le haut. Proche de 0 : elle ne joue pas.

Des scores qui ne se répètent pas

F2 n'apporte que ce que F1 n'avait pas. 13 variables redondantes deviennent quelques scores **non redondants**, rangés par importance.

CE QUE CALCULE L'ORDINATEUR

Vecteur propre = une direction, valeur propre = une quantité d'information

Vecteur propre

Une **direction naturelle** du nuage : la longueur, la largeur du ballon.

Il contient les **poids** des variables dans le score : c'est lui qui dit comment **nommer l'axe**.

Valeur propre λ


À quel point le nuage est **étalé** dans cette direction.

C'est la **quantité d'information** de l'axe : elle sert à **choisir combien d'axes** garder.

Avec 13 variables, le total vaut 13 : un axe de $\lambda = 2,6$ porte 20 % de l'information et résume à lui seul autant que 2,6 variables.

EXEMPLE FIL ROUGE

Maths et physique : deux axes, deux noms



Les deux notes sont liées (corrélation 0,8) : le nuage est un ballon penché.

F1 · « niveau général en sciences »

≈ moyenne des deux notes. À droite : bon dans les deux.

F2 · « profil maths ou physique »

≈ différence des deux notes. Mieux en maths d'un côté, en physique de l'autre.

EXEMPLE FIL ROUGE

L'ACP est utile quand les variables se répètent

Corrélation entre les notes	Part de F1	Ce que fait l'ACP
0	50 %	Rien à résumer : aucun axe ne domine
0,8	90 %	Un seul axe suffit presque
1	100 %	Les deux notes disent la même chose

Avec $r = 0,8$: $\lambda_1 = 1,8$ et $\lambda_2 = 0,2$, sur un total de 2.

Connaître le **niveau général** d'un élève suffit presque à connaître ses deux notes : on ne perd que 10 %.

La question pour les vins : leurs 13 mesures se répètent-elles **assez** pour que quelques axes les résument ?

EN PYTHON

Trois lignes avec scikit-learn

```
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

Z = StandardScaler().fit_transform(X)    # centrer-réduire
acp = PCA().fit(Z)

acp.explained_variance_ratio_    # part d'inertie
F = acp.transform(Z)            # coordonnées des individus
acp.components_                 # vecteurs propres (lignes)
```

Attention à la convention

scikit-learn divise par $n - 1$. Pour retrouver les λ de l'ACP normée : $\lambda = \text{explained_variance_} \times (n - 1) / n$.

Alternative R

FactoMineR::PCA(X, scale.unit = TRUE)
donne directement valeurs propres, coordonnées et graphiques.

COMBIEN D'AXES ?

Les valeurs propres des 178 vins


Axe	λ (valeur propre)	% d'inertie	% cumulé
F1	4,71	36,2 %	36,2 %
F2	2,50	19,2 %	55,4 %
F3	1,45	11,1 %	66,5 %
F4	0,92	7,1 %	73,6 %
F5	0,85	6,6 %	80,2 %
F6	0,64	4,9 %	85,1 %
...	...	...	...
Total	13	100 %	

Les 3 premiers axes (surlignés) résument **66,5 %** de l'inertie.

Le plan F1–F2 en porte déjà 55,4 %, contre $2 \times 100/13 \approx 15 \%$ pour deux variables d'origine.

COMBIEN D'AXES ?

L'éboulis des valeurs propres



Coude : la décroissance ralentit nettement après le 3^e axe.

Kaiser : 3 valeurs propres dépassent 1 (barres bleues).

Les deux critères s'accordent ici : on retient **3 axes**.

COMBIEN D'AXES ?

Deux critères, et le bon sens

Critère du coude

On garde les axes situés **avant** la rupture de pente de l'éboulis.

Limite : lecture visuelle, parfois ambiguë (plusieurs coudes ou aucun).

Critère de Kaiser

On garde les axes tels que $\lambda > 1$: un axe qui résume plus qu'une variable d'origine.

Limite : valable en ACP normée ; retient souvent trop d'axes quand p est grand.


Critères complémentaires

Un % d'inertie cumulé cible (70 à 80 %, selon le domaine).

Surtout : l'axe doit être **interprétable**. Un axe qu'on ne sait pas nommer n'aide personne.

LIRE LES RÉSULTATS

Le cercle des corrélations (plan F1-F2)



Chaque flèche a pour coordonnées les **corrélations** de la variable avec F1 et F2.

F1 oppose les vins riches en phénols et flavonoïdes aux vins riches en acide malique.

F2 porte l'intensité colorante et l'alcool.

Flèches grises : cendres, magnésium, proanthocyanes.

Quatre règles pour le cercle

Longueur de la flèche

Proche du cercle : variable bien représentée dans le plan.
Courte : mal représentée, on ne l'interprète pas.

Angle aigu

Deux variables bien représentées et proches sont corrélées positivement.

Angle droit

Deux flèches perpendiculaires indiquent des variables non corrélées.

Angle plat

Deux flèches opposées indiquent des variables corrélées négativement.

LIRE LES RÉSULTATS

Nommer les axes : des flèches aux mots

F1 · 36 % de l'information

Tirent vers le +

flavonoïdes 0,92 · phénols totaux 0,86
OD280 0,82 · proanthocyanes 0,68

Tirent vers le –

phénols non flavonoïdes –0,65
acide malique –0,53 · alcalinité –0,52

Nom : « richesse en composés phénoliques »

F2 · 19 % de l'information

Tirent vers le +

intensité colorante 0,84 · alcool 0,76
proline 0,58

Tirent vers le –


teinte –0,44

Nom : « couleur et alcool »

La méthode : repérer les variables les plus corrélées à l'axe, regarder de quel côté elles tirent, chercher ce qu'elles ont en commun, donner un nom.

ÉTUDE DE CAS

Les 178 vins dans le plan F1-F2



Les trois cépages se séparent nettement, **sans que l'ACP ait utilisé l'étiquette**.

F1 (phénols) oppose le cépage 1 au cépage 3.

F2 (couleur, alcool) isole le cépage 2, moins coloré.

Le cépage est une **variable illustrative** : projetée après coup.

ÉTUDE DE CAS

Lire un vin : le portrait du vin n° 15

Sa position

F1 = **+4,3** : très à droite

F2 = **+2,1** : en haut

Lecture attendue : **riche en phénols, coloré et alcoolisé.**

Variable	Écart à la moyenne
proline	+2,5
proanthocyanes	+2,4
alcool	+1,7
flavonoïdes	+1,6
phénols totaux	+1,6
intensité colorante	+1,1
alcalinité des cendres	-2,3

Les données d'origine **confirment** la lecture des axes.

ÉTUDE DE CAS

Le piège du centre : le vin n° 97

Sa position

$F1 = -0,5 \cdot F2 = -0,4$

Presque au centre : il a l'air d'un vin **moyen**.

Variable	Écart à la moyenne
magnésium	+2,4
cendres	+1,4
phénols non flavonoïdes	-1,8
alcool	-1,5

En réalité, il est **extrême** sur des variables mal représentées dans le plan.

Règle : proche du centre ne veut pas dire moyen.

Revenir aux données : les cépages en chiffres

	flavonoïdes	acide malique	intensité colorante	alcool
Cépage 1	2,98	2,01	5,53	13,7
Cépage 2	2,08	1,93	3,09	12,3
Cépage 3	0,78	3,33	7,40	13,2
Moyenne	2,03	2,34	5,06	13,0

Cépage 1, à droite

Le plus riche en flavonoïdes : c’est bien le côté « phénols » de F1.

Cépage 3, à gauche en haut

Peu de flavonoïdes, plus d’acide malique, très coloré.

Cépage 2, en bas

Le moins coloré et le moins alcoolisé : le côté négatif de F2.

À RETENIR

La démarche d'une ACP en six étapes

1

Préparer

Variables quantitatives, valeurs manquantes traitées, réduire si unités différentes

2

Choisir k

Éboulis, Kaiser, % cumulé, interprétabilité

3

Nommer les axes

Cercle des corrélations, variables les plus corrélées

4

Placer les individus

Vérifier que la position est fidèle : proche du centre ne veut pas dire moyen

5

Illustrer

Projeter des variables supplémentaires

6

Conclure

Revenir aux données d'origine pour confirmer

TRAVAUX DIRIGÉS · PYTHON

À vous : 50 ans d'économie américaine en ACP

1 · Explorer

Corrélations entre 9 indicateurs macro : pourquoi les résumer ?

2 · Réaliser

ACP normée, valeurs propres, nombre d'axes à garder.

3 · Interpréter

Nommer les axes, lire les décennies, les récessions et les trimestres atypiques.

4 · Utiliser

Un indicateur d'activité et une note de conjoncture.

Individus : contribution et qualité de représentation

Contribution à l'axe k

$$\text{CTR}_k(i) = (1/n) \cdot F_{ik}^2 / \lambda_k$$

Part de l'inertie de l'axe due à l'individu i. Somme sur i = 100 %. Repérer les individus au-dessus de la moyenne 100/n %, qui « font » l'axe.

Qualité : le $\cos^2$

$$\cos^2_k(i) = F_{ik}^2 / d^2(i, G)$$

Carré du cosinus de l'angle entre l'individu et l'axe.
Proche de 1 : bien représenté. On additionne les $\cos^2$ pour un plan.

Règle d'or : on n'interprète la position d'un individu que s'il est bien représenté dans le plan regardé.