

Classification non supervisée

Regrouper les individus qui se ressemblent en quelques classes, sans connaître les groupes à l'avance.

DÉROULÉ

PLAN

Pourquoi classer ?

De l'ACP à la classification ; les usages en banque et en finance

Les concepts clés

Distance, inertie intra et inter, bonne partition

Deux méthodes

k-means et classification ascendante hiérarchique (CAH)

Combien de classes ?

Coude, silhouette, dendrogramme

Étude de cas

1 705 grandes entreprises, deux pièges, un portefeuille d'actions, puis le TD

LE POINT DE DÉPART

Le même tableau, une autre question

	CA / actif	marge nette	capi. / actif	classe
BNP Paribas	0,06	9,9 %	0,08	1
Carrefour	2,42	1,5 %	0,93	2
L'Oréal	1,25	10,7 %	4,00	3
⋮	⋮	⋮	⋮	⋮
Hermès	0,79	17,7 %	4,62	3

Les 1 705 entreprises du classement Forbes Global 2000 de 2004 qui dégagent un bénéfice, décrites par trois ratios financiers.

Séance précédente · l'ACP

résume les **colonnes** : 3 ratios → 2 axes.

Aujourd'hui · la classification

regroupe les **lignes** : 1 705 entreprises → 3 classes.

Le résultat tient en une colonne de plus : la **classe** de chaque individu.

L'IDÉE DE LA CLASSIFICATION

Former des groupes d'individus qui se ressemblent entre eux et qui diffèrent des autres groupes.

Ici, « se ressembler » veut dire **être proches** : une petite distance entre deux profils, mesurée sur toutes les variables à la fois. Personne ne fournit les groupes : la méthode les propose, à nous de les nommer.

POURQUOI CLASSER ?

En banque et en finance, on classe partout

Segmenter la clientèle

Adapter offres, tarifs et canal de contact à chaque type de client.

Prévenir le risque

Repérer les profils qui cumulent découverts et incidents, avant le défaut.

Classer les banques

La BCE a classé 365 banques de la zone euro en quatre modèles d'affaires (Farnè et Vouldis, 2017).

Régimes de marché

Regrouper les périodes semblables (croissance, inflation, taux) pour adapter l'allocation d'actifs.

Diversifier un portefeuille

Regrouper les actifs qui évoluent ensemble pour ne pas concentrer le risque (Mantegna, 1999).

Détecter des anomalies

Une opération loin de toutes les classes mérite un second regard : fraude, erreur de saisie.

POURQUOI CLASSER ?


Non supervisé : pas de réponse à imiter

	Classement · supervisé	Classification · non supervisée
Ce que l'on connaît	Pour chaque client passé, une étiquette : défaut ou non	Seulement les variables, aucune étiquette
La question	À quelle catégorie connue rattacher un nouveau client ?	Quels groupes existent dans les données ?
Exemple bancaire	Scoring de crédit (régression logistique)	Segmentation de la clientèle
Mot anglais	classification	clustering

Attention au faux ami : en français, « classification » désigne souvent le clustering ; en anglais, *classification* désigne l'apprentissage supervisé. Dans scikit-learn, les méthodes de ce cours sont dans **sklearn.cluster**.

EXEMPLE FIL ROUGE

Douze clients, deux variables, trois groupes



Douze clients d'une agence, décrits par leur **âge** et leur **épargne** (en milliers d'euros).

À l'œil, trois groupes : des jeunes peu épargnants (A à D), des quadragénaires aisés (E à H), des retraités (I à L).

Avec 9 variables, ou 1 705 entreprises, l'œil ne suffit plus : il faut une **mesure de ressemblance** et un **algorithme**. C'est l'objet de la suite.

CONCEPT 1

Se ressembler, c'est être proche

$\text{distance}^2 = (\text{écart d'âge})^2 + (\text{écart d'épargne})^2 + \dots$ sur toutes les variables

Client	Âge	Épargne
Léa	25 ans	5 000 €
Marc	65 ans	5 500 €
Inès	27 ans	9 000 €

En unités brutes

Léa – Marc : $\sqrt{(40^2 + 500^2)} \approx 502$

Léa – Inès : $\sqrt{(2^2 + 4\,000^2)} \approx 4\,000$

Les euros écrasent les années : Léa ressemblerait à Marc, 65 ans.

Centrées-réduites

Écarts-types : âge ≈ 16 ans, épargne $\approx 20\,000$ €

Léa – Marc : $\sqrt{(2,5^2 + 0,03^2)} \approx 2,5$


Léa – Inès : $\sqrt{(0,13^2 + 0,2^2)} \approx 0,24$

Léa ressemble bien à Inès : chaque variable pèse autant.

Règle : on centre-réduit avant de calculer des distances, exactement comme pour l'ACP.

CONCEPT 2

L'inertie se partage entre les classes



Inertie totale = inertie intra + inertie inter

Totale : la dispersion de tous les clients autour du centre général G (le carré).

Intra : la dispersion à l'intérieur de chaque classe, les traits fins entre chaque client et le centre de sa classe (la croix).

Inter : l'écart entre les classes, les traits épais entre les centres de classes et G.

Bonne partition : intra petite, inter grande. $R^2 = \text{inter} / \text{totale}$ mesure la part de l'information portée par les classes. Ici, $R^2 = 95 \%$.

CONCEPT 3

Une bonne partition : compacte et bien séparée

Des classes compactes

Les individus d'une même classe se ressemblent : l'inertie intra est petite.

Des classes séparées

Les classes diffèrent nettement les unes des autres : l'inertie inter est grande.

Des classes nommables


On sait dire en une phrase qui est dans chaque classe. Une classe qu'on ne sait pas nommer n'aide personne.

Le piège du nombre de classes

Plus on fait de classes, plus l'inertie intra baisse : avec une classe par individu, elle est nulle... et l'on n'a rien résumé. Le nombre de classes k est un compromis entre fidélité et simplicité.


MÉTHODE 1 · K-MEANS

Quatre étapes, répétées jusqu'à stabilité




1 · Choisir k centres

$k = 3$: trois clients tirés au hasard servent de centres (croix).




2 · Affecter

Chaque client rejoint le centre le plus proche.



3 · Recentrer

Chaque centre va au milieu de sa classe, puis on réaffecte.



4 · Recommencer

On répète 2 et 3 jusqu'à ce qu'aucun client ne change de classe.

Ce qu'il faut savoir avant de l'utiliser

Il converge toujours

À chaque étape, l'inertie intra baisse : l'algorithme s'arrête en quelques itérations, même sur des millions de clients.

Vers un optimum local

Le résultat dépend des centres de départ : on relance plusieurs fois (n_{init}) et l'on garde la partition d'inertie intra minimale.


k est fixé à l'avance

C'est à nous de choisir le nombre de classes ; la partie « Combien de classes ? » donne les outils.

Il préfère les classes rondes

Il découpe l'espace autour des centres : mal adapté aux classes allongées ou de tailles très inégales ; les points extrêmes tirent les centres.

Fusionner pas à pas : l'arbre des ressemblances



1. Au départ, chaque client forme une classe.
2. On fusionne les deux classes les plus proches.
3. On recommence jusqu'à n'avoir plus qu'une classe.

Critère de Ward

Fusionner les deux classes dont la réunion fait le moins augmenter l'inertie intra. La hauteur d'une fusion mesure l'information perdue.

DEUX MÉTHODES

k-means ou CAH ? En pratique, les deux

	k-means	CAH de Ward
Principe	Déplacer k centres jusqu'à stabilité	Fusionner pas à pas les classes les plus proches
Nombre de classes	Fixé avant le calcul	Choisi après, en coupant l'arbre
Hasard	Dépend du départ : relancer (n_init)	Aucun : toujours le même arbre
Gros fichiers	Rapide, même sur des millions de lignes	Lent : toutes les distances deux à deux

La démarche classique

ACP → CAH de Ward sur les premiers axes, pour choisir k → k-means démarré des centres de la CAH, pour consolider. C'est ce que fait **FactoMineR::HCPC** en R.

EN PYTHON

Quelques lignes avec scikit-learn et SciPy

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from scipy.cluster.hierarchy import linkage, fcluster

Z = StandardScaler().fit_transform(X) # centrer-réduire
km = KMeans(n_clusters=3, n_init=10, random_state=0).fit(Z)
km.labels_    # classe de chaque individu
km.inertia_   # inertie intra (somme des carrés)
silhouette_score(Z, km.labels_)

arbre = linkage(Z, method="ward") # CAH de Ward
classes = fcluster(arbre, t=3, criterion="maxclust")
```

Attention à inertia_


C'est une somme de carrés sur tous les individus : divisez par n pour retrouver la convention du cours (inertie totale = nombre de variables).

Alternative R


FactoMineR::HCPC(PCA(X)) enchaîne ACP, CAH de Ward et consolidation par k-means.

COMBIEN DE CLASSES ?

Le coude et la silhouette des 1 705 entreprises




Coude : selon le nombre de classes k , l'inertie intra (par entreprise) chute jusqu'à 3 classes, puis ne baisse plus que lentement.



Silhouette : la plus haute pour 2 classes, puis pour 3. Pour chaque entreprise, $s = (b - a) / \max(a, b)$, avec a sa distance moyenne à sa classe et b à la classe voisine : proche de 1, bien classée ; proche de 0, entre deux classes.

COMBIEN DE CLASSES ?


Le dendrogramme des 1 705 entreprises



Les deux dernières fusions (hauteurs de Ward 45,9 et 58,4) coûtent bien plus que les précédentes (29,6 au plus) : on coupe en **3 classes**. La silhouette préférerait 2 classes : elles séparent seulement les financières du reste. On retient 3.

ÉTUDE DE CAS

Les 3 classes du k-means dans le plan de l'ACP



Le k-means est calculé sur les 3 ratios, passés au log et centrés-réduits ; le plan de l'ACP sert seulement à voir le résultat. F1 suit le chiffre d'affaires et la capitalisation par dollar d'actif ; F2, surtout la marge.

Classe 1, à gauche : peu de CA et de capitalisation pour un actif énorme.

Classe 3, en haut à droite : capitalisation et rentabilité fortes.

Classe 2, en bas à droite : du volume, peu de marge.

AXA, assureur, tombe dans la classe 2 : sa marge nette n'est que de 1,1 %.

À 3 classes, la CAH de Ward range 85 % des entreprises comme le k-means.

ÉTUDE DE CAS

Le k-means isole les banques sans les connaître

99,6 %

des banques sont dans la classe 1 : 272 sur 273.

Le secteur n'a pas servi au calcul : c'est une variable illustrative, comme en ACP. La classe 1 est financière à 96 % ; 10 de ses 18 entreprises non financières sont des services aux collectivités (eau, électricité, gaz), aux actifs très lourds.

	Banques	Assurances	Autres financières	Non financières	Total
Classe 1	272	38	84	18	412
Classe 2	1	18	12	426	457
Classe 3	0	26	43	767	836
Total	273	82	139	1 211	1 705

ÉTUDE DE CAS

Portrait des classes : leur donner un nom

Médianes	CA / actif	marge nette	capi. / actif	bénéfice / actif
Classe 1 (412 entreprises)	0,07	11,5 %	0,15	0,9 %
Classe 2 (457 entreprises)	1,00	2,0 %	0,49	1,8 %
Classe 3 (836 entreprises)	0,71	9,5 %	1,33	7,0 %
Ensemble (1 705)	0,60	7,0 %	0,68	3,5 %

Classe 1 • « bilans lourds »

7 cents de CA par dollar d'actif, moins de 1 % de bénéfice sur l'actif : banques et autres financières.

Classe 2 • « volume »

Autant de CA que d'actif, mais 2 % de marge : négoce, supermarchés, automobile.

Classe 3 • « rentables »


Une capitalisation au-dessus de l'actif, 7 % de bénéfice sur l'actif : pharmacie, logiciel, pétrole.

La méthode : comparer chaque classe à l'ensemble, repérer les grands écarts, voir ce qu'ils ont en commun, donner un nom.

LES PIÈGES


k-means trouve toujours des classes

Premier tirage · inertie intra : 6,005



Les 202 trimestres de l'économie américaine (séance précédente), 9 indicateurs, k-means à 4 classes lancé deux fois : même inertie, mais **39 % des trimestres changent de classe**.

Second tirage · inertie intra : 6,004



Silhouette $\approx 0,15$, contre 0,39 pour les entreprises : les trimestres forment un continuum, pas des groupes. Avant d'interpréter : relancer, comparer avec la CAH, lire la silhouette.

À RETENIR

La démarche d'une classification en six étapes

1

Préparer

Choisir les variables, centrer-réduire, passer au log les montants très asymétriques

2

Classer

k-means, CAH de Ward, ou les deux : la CAH pour choisir, k-means pour consolider

3

Choisir k

Coude, silhouette, dendrogramme, et surtout des classes que l'on sait nommer

4

Décrire

Comparer chaque classe à la moyenne générale, en écarts-types puis en unités d'origine

5

Valider

Stabilité (plusieurs tirages, deux méthodes) et variables illustratives

6

Utiliser

Classer les nouveaux individus avec la même préparation, agir classe par classe

TRAVAUX DIRIGÉS · PYTHON

À vous : segmenter les 2 000 clients d'une banque

1 · Préparer

Lire le fichier Excel, repérer les asymétries, passer au log, centrer-réduire.

2 · Classer

k-means, choix du nombre de classes, stabilité des résultats.

3 · Interpréter

Nommer les segments, les confronter au risque de défaut, les placer sur la carte de l'ACP.

4 · Utiliser

CAH de contrôle, classement de nouveaux clients, note au comité de direction.

Les formules derrière les méthodes

Décomposition de l'inertie

$$I_{\text{totale}} = I_{\text{intra}} + I_{\text{inter}}$$

$$I_{\text{inter}} = \sum [n(k) / n] \cdot d^2(g(k), G)$$

$g(k)$: centre de la classe k , $n(k)$: son effectif, G : centre général. La méthode k -means rend I_{intra} minimale, donc I_{inter} maximale.

Critère de Ward

$$\Delta(A, B) = n(A) \cdot n(B) / (n(A) + n(B)) \cdot d^2(g(A), g(B))$$

La hausse de l'inertie intra (en somme de carrés) quand on fusionne A et B . Ward fusionne à chaque étape la paire de Δ minimal ; dans SciPy, la hauteur de fusion vaut $\sqrt{(2\Delta)}$.

Silhouette

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

$a(i)$: distance moyenne de i aux autres membres de sa classe ; $b(i)$: à ceux de la classe voisine la plus proche. Entre -1 et 1 ; on lit la moyenne sur tous les individus.

Règle d'or : on n'interprète une classe que si elle est stable (elle résiste à un autre tirage ou à une autre méthode) et que l'on sait la nommer.

Au-delà des k-means : quatre méthodes à connaître

k-médoïdes (PAM)

Le centre de chaque classe est un individu réel, le plus central. Plus robuste aux valeurs extrêmes, et compatible avec n'importe quelle distance.

`scikit-learn-extra : KMedoids`

Mélanges gaussiens

Chaque classe est une loi normale ; chaque individu reçoit une probabilité d'appartenance à chaque classe. Classes de forme elliptique.

`sklearn.mixture.GaussianMixture`

DBSCAN

Une classe est une zone dense ; les points isolés restent hors classe (anomalies, fraude). Pas de k à fixer, mais un rayon de voisinage à choisir.

`sklearn.cluster.DBSCAN`

Variables qualitatives

Profession, type de contrat, canal : ACM puis CAH sur les axes, ou k-prototypes pour mélanger variables quantitatives et qualitatives.

`kmodes : KPrototypes`