Projet d'analyse de données

Le projet en bref

Vous allez mener, en groupe, une analyse de données complète sur un sujet de votre choix, de la donnée brute jusqu'à une présentation orale qui raconte une histoire.

Le projet repose sur trois piliers, qui s'enchaînent :

1. **Récupérer un dataset** : trouver une source fiable, comprendre ce que contiennent les données et les charger proprement.
2. **Appliquer les méthodes du cours** : nettoyage, exploration, statistiques, visualisation et, si pertinent, modélisation.
3. **Raconter l'analyse** : une présentation de type storytelling qui part d'une question et aboutit à des conclusions claires.

Pilier 1 - Choisir un bon dataset

Commencez par une question qui vous intéresse, puis cherchez les données qui permettent d'y répondre, pas l'inverse. Un sujet qui vous parle (sport, santé, climat, logement, musique, transports…) rendra la présentation bien plus vivante.

Où trouver des datasets

Privilégiez les portails officiels : les données y sont documentées, sourcées et souvent riches en questions à explorer.

Portails français et européens

Source	Ce qu'on y trouve	Idées de sujets
data.gouv.fr	Portail national de l'open data, des milliers de jeux	Accidents de la route, prix des carburants, élections
INSEE	Démographie, emploi, revenus, données par commune	Inégalités territoriales, chômage par région
DVF (valeurs foncières)	Toutes les ventes immobilières depuis 2014	Prix au m², effet de la distance aux grandes villes
Météo-France (meteo.data.gouv.fr)	Relevés météo historiques par station	Évolution des températures, vagues de chaleur

Source	Ce qu'on y trouve	Idées de sujets
SNCF Open Data	Régularité des trains, fréquentation des gares	Retards selon la saison ou la ligne
Open Food Facts	Composition et Nutri-Score de millions de produits	Nutri-Score par marque ou catégorie
Eurostat	Statistiques comparables entre pays de l'UE	Énergie, santé, éducation en Europe

Sources internationales

Source	Ce qu'on y trouve	Idées de sujets
Our World in Data	Indicateurs mondiaux propres et bien documentés	Climat, santé, énergie, pauvreté
Banque mondiale	Indicateurs économiques et sociaux par pays	PIB, espérance de vie, éducation
OCDE	Statistiques des pays de l'OCDE	Salaires, temps de travail, logement
UCI ML Repository	Datasets académiques classiques, bien décrits	Classification, régression

Moteurs et plateformes communautaires

Source	Usage	Point de vigilance
Kaggle Datasets	Énorme choix, sujets très variés (sport, jeux vidéo, Spotify…)	Vérifier l'origine réelle des données et ne pas recopier les notebooks existants
Google Dataset Search	Moteur de recherche dédié aux jeux de données	Qualité très inégale selon les résultats
Hugging Face Datasets	Textes, avis, données tabulaires	Plutôt orienté IA, souvent volumineux

Pilier 2 - Appliquer les méthodes du cours

Votre notebook doit montrer une démarche complète et justifiée : chaque étape répond à la question posée, et chaque choix est expliqué en une ou deux phrases.

1. **Problématique** : une question principale et deux ou trois sous-questions, écrites en tête du notebook.
2. **Chargement et description** : source, date,, dimensions du jeu, signification de chaque variable utilisée.
3. **Nettoyage** : valeurs manquantes, doublons, types, valeurs aberrantes, recodages. Indiquez combien de lignes vous retirez et pourquoi.
4. **Analyse exploratoire** : statistiques descriptives, distributions, corrélations, comparaisons entre groupes.
5. **Visualisation** : des graphiques choisis pour leur message (pas de graphique décoratif), avec titres, axes et unités.
6. **Méthodes avancées vues en cours** (selon le sujet) : tests statistiques, régression, ACP, clustering, classification… Une méthode bien justifiée vaut mieux que cinq appliquées sans réflexion.
7. **Interprétation et limites** : ce que les résultats disent, ce qu'ils ne disent pas (corrélation n'est pas causalité, biais de la source, taille de l'échantillon)..

Pilier 3 - Raconter l'analyse (storytelling)

Imaginez que vous parlez à un décideur qui n'a pas vu vos données.

Structure conseillée :

1. **L'accroche** : un chiffre frappant, une situation concrète ou une question qui interpelle.
2. **Le contexte et la question** : pourquoi ce sujet compte, ce que vous cherchez à savoir.
3. **Les données** : d'où elles viennent, ce qu'elles couvrent, leurs limites (une diapositive suffit).
4. **Le développement** : trois ou quatre résultats clés, chacun porté par un graphique et une phrase-message.
5. **Le moment fort** : le résultat le plus surprenant ou le plus important.
6. **La conclusion** : la réponse à la question, les limites, et ce qu'on pourrait faire ensuite.